O cérebro, na prática

O que muda ao usar a memória do widget com o Claude Code, comparado ao uso normal

A resposta curta

Sem o cérebro, **toda conversa com a IA começa do zero**: ela não sabe o que você decidiu na semana passada, nem por quê. Você explica de novo, cola trechos de chats antigos ou deixa a IA descobrir tudo sozinha, e os três jeitos custam tempo e tokens. O cérebro é uma **memória em arquivos pequenos** (resumos de conversas e o estado de cada projeto) que a IA consulta antes de pesquisar. Ela encontra o que importa, abre no máximo 3 arquivos e já começa alinhada com o que foi decidido.

> **Em uma frase:** o cérebro troca *"explicar tudo de novo"* por *"ler 2 ou 3 resumos certos"*.
> O ganho mais seguro é de **continuidade e qualidade** (decisões não se perdem). A economia de tokens existe, mas cresce com o tamanho do histórico, e ainda **não foi medida com números reais**: este documento separa o que está medido do que é estimativa.

Lado a lado

	Uso normal	Com o cérebro
Começo de cada conversa	A IA não sabe nada. Você explica de novo, ou ela relê o código e faz perguntas.	A IA consulta a memória do projeto (estado e decisões) em 1 chamada, antes de pesquisar.
Decisões antigas	Ficam perdidas no meio de chats. Você precisa lembrar que existem e achar.	Resumidas em arquivos curtos, pesquisáveis por projeto e palavra-chave.
Quanto contexto entra	Ou pouco (a IA erra e refaz) ou tudo (caro).	Só o que combina: o estado do projeto e até 3 arquivos.
Limite de uso atingido	Você perde o fio e recomeça explicando.	"Pausar com segurança" grava o estado; depois a IA retoma lendo-o.
Chats em outros sites	Claude.ai, ChatGPT e Gemini guardam memórias separadas. Nada é compartilhado.	As conversas antigas são importadas e resumidas para o mesmo cérebro.
Controle	Você não vê o que a IA "lembra".	Arquivos de texto seus, legíveis, com grafo 3D. Nada roda sozinho: só quando você clica.

O problema do uso normal

A IA não guarda lembrança de uma conversa para a outra. Cada sessão nova é uma folha em branco, e o que existe de "memória" fica espalhado em chats que você teria que reler. Isso tem três custos:

- **Tempo:** reexplicar o projeto, procurar o chat certo, achar a decisão antiga.
- **Tokens:** quanto mais contexto você cola "por garantia", mais caro cada conversa fica. Colar pouco sai barato, mas a IA erra.
- **Retrabalho:** sem saber o que já foi decidido, a IA propõe de novo o que você já descartou, e você gasta uma rodada só para corrigir.

O mesmo trabalho, de dois jeitos



No uso normal a seta termina em perda: o que foi aprendido some quando a conversa acaba. Com o cérebro o ciclo se fecha, porque o fim de uma sessão (o **/compactar**) vira o começo da próxima.

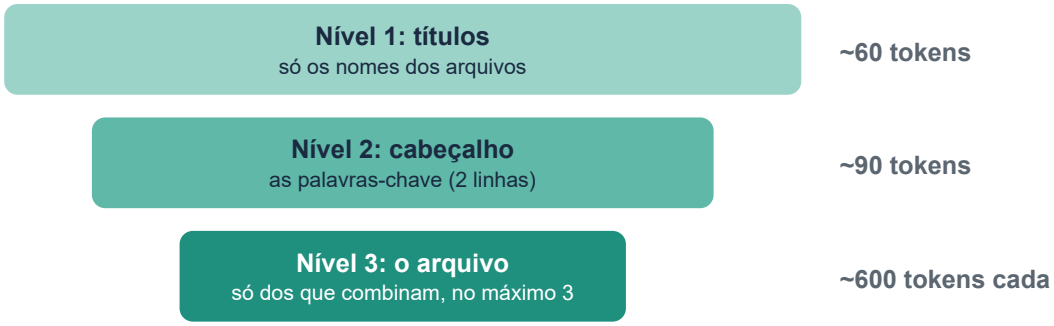
Como o cérebro funciona

1. Guardar pouco, e guardar bem

No fim de uma sessão produtiva você usa **/compactar**. A IA escreve um resumo de, no máximo, **12 tópicos ou 150 palavras** (o que foi decidido, o que funcionou, o que ficou pendente) e, se preciso, atualiza o **estado do projeto**: um arquivo de 6 seções (Objetivo, Stack, Decisões, Estado atual, Próximos passos, Armadilhas) com no máximo 300 palavras. O formato é validado, e senhas e chaves são recusadas.

2. Achar barato: a busca em 3 níveis

Em vez de abrir tudo, a busca começa pelo que é mais barato e só avança se precisar. Hoje a skill **cerebro-buscar** faz isso em **uma única chamada** e sugere, no máximo, 3 arquivos para abrir.



a busca pára assim que achar o que precisa

Os tamanhos acima são os valores padrão estimados do projeto; a aba Skills troca esses valores pela média real das suas buscas quando já existem dados.

3. Retomar sem reexplicar

Ao abrir o Claude pelo widget, o prompt inicial já manda consultar o cérebro. Se o limite de uso acabar no meio do trabalho, **"Pausar com segurança"** compacta a sessão, atualiza o estado e anota a pausa. Quando o uso voltar, **"Continuar da pausa"** abre uma sessão nova que lê o estado e segue de onde parou.

> ### Leve e sob o seu controle
> Tudo fica na sua máquina, em arquivos Markdown. Nada roda em segundo plano: a busca, a manutenção e o grafo só trabalham quando você pede, e tarefas que usam IA (resumir, consolidar) sempre mostram a estimativa de tokens e pedem confirmação antes.

Um exemplo lado a lado

> **Cenário (ilustrativo):** você volta, numa segunda-feira, a um projeto que parou há 3 semanas. Na época, ficou decidido que a colisão do carro usaria *raycast* e que o placar ficaria no servidor.

	Uso normal	Com o cérebro
1. Abrir a conversa	Conversa nova. A IA não sabe nada do projeto.	Você abre o Claude pelo widget. O prompt inicial manda consultar o cérebro.
2. Dar o contexto	Você tenta lembrar e digita um resumo de memória. Esquece o detalhe do placar.	A IA roda *buscar*: vê o estado do projeto e quais resumos combinam com o pedido.
3. Ler o que importa	Se quiser ser completo, cola chats antigos inteiros (caro) ou procura em vários lugares.	Abre só os 2 ou 3 arquivos certos (máximo 3) e diz em 1 linha o que achou.
4. Trabalhar	A IA sugere guardar o placar no cliente. Você percebe e corrige: uma rodada perdida.	A IA já sabe que o placar fica no servidor e segue a decisão.
5. Terminar	A conversa fecha. O que foi aprendido hoje some.	**/compactar** guarda as novas decisões. Na próxima vez, o ponto de partida é melhor.

Observe que o ganho não é só de tokens: é a **decisão que não foi esquecida** e a **rodada que não foi gasta** corrigindo a IA. Esse tipo de ganho é difícil de medir em tokens, mas é o que mais aparece no dia a dia.

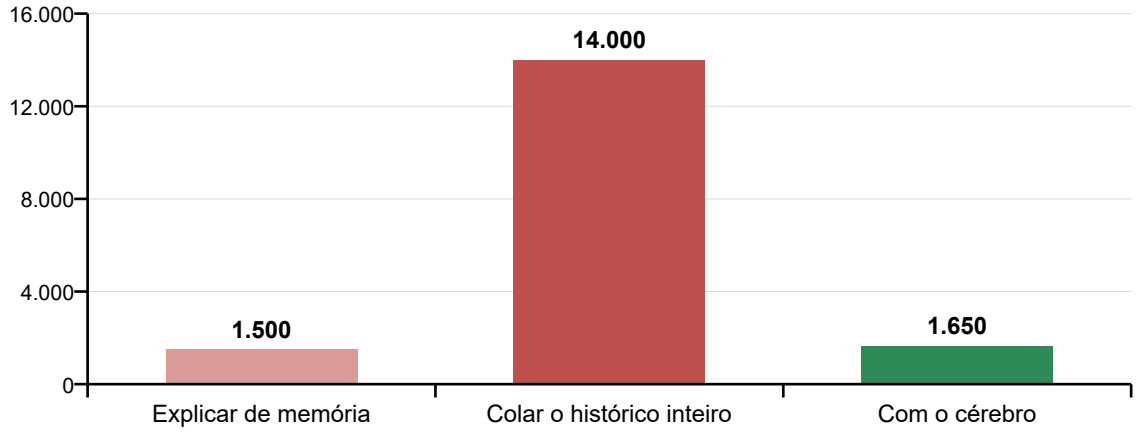
E em números?

Atenção: os números desta página são um **exemplo ilustrativo**, calculado com premissas explícitas. Não são uma medição do seu uso real. A medição real é o teste A/B descrito na última página.

Premissas do exemplo

- Um projeto com **40 resumos** de conversas, de cerca de 350 tokens cada: o histórico completo tem **~14.000 tokens**.
- O estado do projeto tem ~400 tokens. A saída da busca tem ~200 tokens. Cada arquivo aberto tem ~350 tokens (no máximo 3).
- "Explicar de memória": um resumo curto que você escreve, de ~1.500 tokens. "Colar o histórico": tudo, para não esquecer nada.

tokens de contexto que entram no começo de uma conversa (exemplo ilustrativo)



	Uso normal	Com o cérebro
Uso normal A	**Explicar de memória**: ~1.500 tokens. Barato, mas incompleto: o que você esquece não entra.	**Com o cérebro**: ~400 (estado) + ~200 (busca) + até ~1.050 (3 arquivos) = **~1.650 tokens**, só o que combina.
Uso normal B	**Colar tudo**: ~14.000 tokens. Completo, mas paga o histórico inteiro a cada conversa.	Com 10 conversas por semana: ~140.000 tokens colando tudo contra ~16.500 com o cérebro (exemplo).

Leitura honesta: o cérebro **não é mais barato que escrever um resumo curto de memória**; ele custa parecido e traz mais precisão (os detalhes certos, no lugar certo). Ele é **muito mais barato que colar o histórico**, e a diferença cresce junto com o histórico. Há também um custo fixo pequeno: as duas skills do cérebro somam ~107 tokens por conversa (valor medido no projeto).

O que já está medido, e o que ainda não está

Medido no projeto (28/10/2026)

Item	Resultado
Velocidade da busca	Com 1.000 arquivos: nível 1 em ~11 ms, nível 2 em ~105 ms, busca combinada em ~14 ms. Como processo completo: ~230 a 330 ms.
Limite de arquivos	A busca sugere, e a leitura aceita, no máximo 3 arquivos por vez (testado).
Custo fixo por conversa	As 2 skills do cérebro somam ~107 tokens. O imposto fixo total (skills, plugins e regras) caiu de 3.296 para 2.548 tokens no projeto depois da limpeza, e chega a ~4.100 se contar as skills de plugins.
Segurança	Nenhuma chave no histórico do git; limpeza de segredos ativa na importação; o projeto só é enviado ao repositório privado (um bloqueio impede o envio ao público).

Ainda NÃO provado

- **A economia real de tokens.** O painel "Economia" estima, mas com só 2 conversas no cérebro a estimativa de hoje dá **negativa** (cerca de -1.357 tokens). Isso é esperado: quase não há histórico para evitar de reexplicar. Ela só faz sentido depois que o cérebro tiver conteúdo.
- **A qualidade das respostas.** Gastar menos token não vale se a resposta piorar. O teste A/B pede que você anote a qualidade de 1 a 5.
- **O ganho de tempo.** Não foi cronometrado.

Quando o cérebro NÃO compensa

- Projetos pequenos ou tarefas de uma conversa só: não há o que lembrar.
- Cérebro vazio ou sem hábito de usar **/compactar**: ele só devolve o que foi guardado.
- Quando você já escreve, toda vez, um bom resumo de poucas linhas: nesse caso o ganho é mais de organização do que de tokens.

O que mais o cérebro oferece

- **Pausar com segurança e retomar:** acabou o limite? O estado é gravado e a próxima sessão continua sem reexplicar. Não existe nenhuma troca automática de contas.
- **Importar conversas antigas** do Claude, ChatGPT e Gemini: o importador limpa segredos, escolhe as que valem a pena e resume só as marcadas, com estimativa e confirmação a cada lote.
- **Manutenção:** acha arquivos parados, palavras-chave quase iguais e resumos parecidos; consolida (sem apagar nada) e faz backup datado.
- **Grafo 3D:** o cérebro como um mapa de estrelas (um projeto por estrela) em que você gira, amplia e move cada arquivo.
- **Economia e teste A/B:** um painel mostra se o cérebro está compensando e um roteiro permite comparar a mesma tarefa com e sem ele.

Como começar a ver o ganho

- **1. Encher o cérebro.** Importe suas conversas antigas (*importar.py rodar*, depois *resumir --simular* para ver 3 de amostra) e use **/compactar** no fim de sessões produtivas.
- **2. Abrir o Claude pelo widget** (aba Projetos): o prompt inicial já manda consultar o cérebro.
- **3. Deixar acumular** por 2 a 3 semanas de uso normal.
- **4. Medir de verdade:** faça o teste A/B do roteiro *docs/teste-economia.md* (a mesma tarefa com e sem o cérebro, anotando o que o **/usage** mostrar) e registre no painel "Economia".

> **Regra do jogo**
> Se o teste A/B mostrar que o cérebro gastou **mais** tokens numa tarefa, vale o resultado do teste, não a estimativa. Foi pensado assim: o cérebro tem que provar, com os seus números, que compensa.

Fontes: medições do próprio projeto (cerebro/tools, 28/10/2026), docs/WIDGET.md, cerebro/README.md e docs/teste-economia.md.